

2026.08.19(수)


## 5장. 텍스트 클러스터링과 토픽 모델링

: Hands-On Large Language Models

---

## 텍스트 클러스터링의 중요성

- 텍스트를 내용, 의미, 관계를 기반으로 비슷한 것끼리 그룹으로 모으는 것을 **클러스터링**이라고 함
- 클러스터링은 효과적인 분류의 기능도 하는 동시에 탐색적 데이터 분석의 수행을 도와줌




1. 우리가 수집한 문서는 동물, 스포츠, 양식 등이겠구나

2. (가정) 동물 클러스터에 밀도가 많다면,  
우리가 수집한 문서 조건에서는 동물 관련 문서가  
많았겠구나!

## 전통적인 텍스트 클러스터링

- 효과적인 군집을 위한 조건은 텍스트를 행렬로 표현하는 것
- 전통적인 텍스트 클러스터링인 LDA와 같은 토픽 모델링은 Document-Term Matrix 구축을 기반으로 하였음
  - 내부적인 모델의 차이는 존재하고 토픽 모델링은 Hard-Clustering 이 아니라는 것에 차이가 있지만...



Document-term Matrix

|            | Term 1 | Term 2 | Term 3 | Term 4 | Term 5 |
|------------|--------|--------|--------|--------|--------|
| Document 1 | 0      | 0      | 1      | 2      | 0      |
| Document 2 | 3      | 1      | 3      | 3      | 1      |
| Document 3 | 0      | 0      | 1      | 0      | 0      |
| Document 4 | 1      | 1      | 4      | 1      | 1      |

## 전통적인 텍스트 클러스터링의 문제점

- 같은 의미의 문서를 다른 문서로 오인하게 될 수 있음

- 휴대폰 배터리가 너무 빨리 닳는다.
- 스마트폰의 전지가 금방 소모된다.

|      | 휴대폰 | 배터리 | 빨리 | 닳다 | 스마트폰 | 전지 | 금방 | 소모된다 |
|------|-----|-----|----|----|------|----|----|------|
| 문장 1 | 1   | 1   | 1  | 1  | 0    | 0  | 0  | 0    |
| 문장 2 | 0   | 0   | 0  | 0  | 1    | 1  | 1  | 1    |

- BoW의 한계에서 자유롭지 못함 (문서의 문맥을 무시하고 단어의 등장 빈도만을 입력 값으로 고려하기 때문)

- 한국이 체코를 이겼다.
- 체코가 한국을 이겼다.

|      | 한국 | 체코 | 이겼다 |
|------|----|----|-----|
| 문장 1 | 1  | 1  | 1   |
| 문장 2 | 1  | 1  | 1   |

## 전통적인 텍스트 클러스터링의 대안

- 한계를 극복하기 위해 텍스트 클러스터링의 파이프라인이 개선되어져 왔음

의미론적 개선을  
위한

임베딩 모델  
사용

차원축소를 사용한

임베딩 벡터  
축소

효과적인  
군집식별을 위한


클러스터링  
모델 선택

## 텍스트 클러스터링 실습

```
# Load data from Hugging Face
from datasets import load_dataset
dataset = load_dataset("maartengr/arxiv_nlp")["train"]

# Extract metadata
abstracts = dataset["Abstracts"]
titles = dataset["Titles"]
```

1991 ~ 2024년까지 등록된 44,949개의  
계산 및 언어 분야의 논문을 사용



임베딩 모델 사용

본 실습에서는 gte small 임베딩 모델을 사용함

## 텍스트 클러스터링 실습

- GTE-small 모델은 General Text Embeddings 의 약자로 영문 패러프레이징 및 텍스트 유사도 검색에 특화된 모델임
- MTED 리더보드에서 목적에 맞는 임베딩 모델을 선택하면 됨

 **English**  
MTEB(eng, v2)

English text embedding quality across classification, clustering, retrieval, reranking, pair classification, and semantic similarity, prioritizing tasks not commonly used for fine-tuning to give a more realistic estimate of generalization performance. The original v1 leaderboard is available under [MTEB\(eng, v1\)](#).

Cite this benchmark

LANGUAGES  
1

TASKS  
41

TASK TYPES  
7

MODELS  
181

SUMMARYPERFORMANCE PER MODEL SIZEPERFORMANCE OVER TIMEPERFORMANCE PER TASKTASK INFORMATION

Q Search models by name...Download CSV

| Rank | Model                                                 | Parameters | Openness | Zero-shot | Mean (Task) | Mean (Ta |
|------|-------------------------------------------------------|------------|----------|-----------|-------------|----------|
| #1   | jcorners <a href="#">ingot-8b-r3</a>                  | 7.6 B      |          | 82%       | 75.98       |          |
| #2   | infgrad <a href="#">Jasper-Token-Compression-600M</a> | 607 M      |          | 48%       | 74.75       |          |
| #3   | Kingsoft-LLM <a href="#">QZhou-Embedding</a>          | 7.1 B      |          | 48%       | 75.97       |          |
| #4   | Qwen <a href="#">Qwen3-Embedding-8B</a>               | 7.6 B      |          | 95%       | 75.23       |          |
| #5   | ByteDance-Seed <a href="#">Seed1.5-Embedding</a>      | —          |          | 51%       | 74.76       |          |

Domain 13

 **Code**  
MTEB(Code, v1)  
Code retrieval quality across a wide range of popular programming languages...

 **Legal**  
MTEB(Law, v1)  
Legal document retrieval across case documents, statutes, legal Q&A, and legal...

 **Medical**  
MTEB(Medical, v1)  
Medical information retrieval across clinical, biomedical, and consumer health domain...

 **Chemical**  
ChemTEB  
Chemical domain text embedding quality across bitext mining, classification,...

Domain-specialised leaderboards such as code, law, medicine, chemistry

benchmarks

## 텍스트 클러스터링 실습

- GTE-small 모델은 384 차원의 임베딩 벡터를 생성함
- 384 차원에서 의미있는 클러스터를 찾는 것이 어려울 수 있어서 차원 축소 방법을 사용함
  - 차원 축소 기법의 목표는 고차원 데이터의 전역 구조를 보존하는 저차원 표현을 찾는 것

```
In [4]: 1 embeddings.shape
        executed in 6ms, finished 10:41:05 2026-08-10
Out [4]: (44949, 384)
```




Figure 5-5. Step 2: The embeddings are reduced to a lower-dimensional space using dimensionality reduction.

## 텍스트 클러스터링 실습

- 어떤 차원 축소를 선택할 것인가?
  - PCA, t-SNE, ... 등의 후보가 존재하며 본 실습에서는 UMAP을 사용함 (비선형 관계를 더 잘 다룰 수 있기 때문에)

```
In [13]: 1 from umap import UMAP
          2 # We reduce the input embeddings from 384 dimensions to 5 dimensions
          3 umap_model = UMAP(
          4     n_components=5, min_dist=0.0, metric='cosine',
          5     random_state=42
          6 )
          7 reduced_embeddings = umap_model.fit_transform(embeddings)

executed in 36.5s, finished 10:51:15 2026-08-10

C:\Users\User\anaconda3\Lib\site-packages\umap\umap_.py:1952: UserWarning: 
no seed for parallelism.
  warn(


In [15]: 1 reduced_embeddings.shape

executed in 4ms, finished 10:51:28 2026-08-10

Out[15]: (44949, 5)
```

## 텍스트 클러스터링 실습

- 어떤 클러스터링을 수행할 것인가?
  - 중심점 기반 (K-means)와 밀도 기반(HDBSCAN) 등이 존재함
  - Arxiv에는 특이한 주제의 논문도 있을 것이라, 모든 클러스터를 강성 할당하는 중심점 기반 방식보다는 밀도 기반의 방식이 더 좋을 것이라 가정




```
Out [18]: 156
```

## 텍스트 클러스터링 실습

- 현재는 5차원 벡터로 Arxiv 등록 논문을 축소하였음
- 이를 시각화 하기 위해서는 2차원에서의 축소가 필요함 (384 → 2)


각 클러스터가 어떤 내용을 담고 있는지는 알 수 없음

텍스트 클러스터링 → 토픽 모델 전환의 필요성!



## BERTopic과 전통적 토픽 모델링의 차이점

- Document Term Matrix를 구축하는 순간 BoW 한계에서 자유로울 수 없음
- BERTopic은 앞서 진행해온 클러스터링과 토픽 해석을 위한 토픽 표현으로 구성됨 (총 5단계 파이프라인)




## BERTopic과 전통적 토픽 모델링의 차이점



- BERTopic은 앞서 진행해온 클러스터링과 **토픽 해석**을 위한 토픽 표현으로 구성됨

- 토픽(클러스터)의 주요 단어를 알아야 함
- 각 토픽(클러스터)는 SBERT의 임베딩 차원 (768)의 벡터에 불과함

- 1) 클러스터 별 문서 병합 → 2) 클러스터 별 주요 단어 식별 (c-TF-IDF 기반) → 3) 클러스터(토픽)명의 해석을 수행할 수 있음




참고) c-TF-IDF 수행을 위한 단어 토큰화, 어휘 사전 구축은 scikit-learn의 CountVectorizer에서 자동으로 수행



## BERTopic 개선하기

- BERTopic은 5단계의 파이프라인으로 구성되어 있으며, 클러스터링과 토픽 해석 단계는 서로 **독립적**임
  - 각 파이프라인은 **모듈화**할 수 있다는 점에서 개선성이 좋은 토픽 모델링임
- BERTopic의 다양한 변종 알고리즘 지원에 대해서..

- Guided topic modeling
- (Semi-)supervised topic modeling
- Hierarchical topic modeling
- Dynamic topic modeling **예) 시간 모듈을 추가하여 시간에 따른 토픽 변화 추이 분석**
- Multimodal topic modeling
- Multi-aspect topic modeling
- Online and incremental topic modeling
- Zero-shot topic modeling
- Etc.



## BERTopic 실습하기

- 기본 BERTopic 모델을 활용해서 실습을 진행함
- HDBSCAN의 앞선 모델에서 156개의 클러스터(토픽)를 식별하였음

```
1 topic_model.get_topic_info()
executed in 13ms, finished 14:30:45 2026-08-10
```

| Topic | Count | -1은 무엇일까? | Name                                          | Representation                                    |
|-------|-------|-----------|-----------------------------------------------|---------------------------------------------------|
| 0     | -1    | 15003     | -1_the_of_and_to                              | [the, of, and, to, in, we, for, that, on, lang... |
| 1     | 0     | 1746      | 0_speech_asr_recognition_acoustic             | [speech, asr, recognition, acoustic, end, spea... |
| 2     | 1     | 1410      | 1_medical_clinical_biomedical_patient         | [medical, clinical, biomedical, patient, healt... |
| 3     | 2     | 976       | 2_translation_nmt_machine_neural              | [translation, nmt, machine, neural, bleu, engl... |
| 4     | 3     | 894       | 3_summarization_summaries_summary_abstractive | [summarization, summaries, summary, abstractiv... |
| ...   | ...   | ...       | ...                                           | ...                                               |
| 151   | 150   | 54        | 150_prompt_prompts_optimization_prompting     | [prompt, prompts, optimization, prompting, llm... |
| 152   | 151   | 53        | 151_mixed_code_sentiment_mixing               | [mixed, code, sentiment, mixing, analysis, eng... |
| 153   | 152   | 51        | 152_moe_experts_mixture_routing               | [moe, experts, mixture, routing, expert, spars... |
| 154   | 153   | 50        | 153_gans_gan_adversarial_generation           | [gans, gan, adversarial, generation, generativ... |
| 155   | 154   | 50        | 154_multimodal_sentiment_modality_fusion      | [multimodal, sentiment, modality, fusion, moda... |

156 rows × 5 columns

```
In [3]: 1 from sentence_transformers import SentenceTransformer
2 # Create an embedding for each abstract
3 embedding_model = SentenceTransformer("thenlper/gte-small")
4 embeddings = embedding_model.encode(abstracts, show_progress_bar=True)
executed in 1m 34.7s, finished 10:40:49 2026-08-10
```

```
1 from bertopic import BERTopic
2 # Train our model with our previously defined models
3 topic_model = BERTopic(
4     embedding_model=embedding_model,
5     umap_model=umap_model,
6     hdbscan_model=hdbscan_model,
7     verbose=True).fit(abstracts, embeddings)
executed in 29.1s, finished 14:30:32 2026-08-10
```

### Build your own topic model




Figure 5-17. The modularity of BERTopic is a key component and allows you to build your own topic model however you want.




## BERTopic 개선하기 : c-TF-IDF의 개선

- c-TF-IDF 방식은 scikit learn에 의한 vectorization이 기반이고, 그보다 앞서 BoW 로 토픽을 해석해야 한다는 한계가 있음
  - 단어 간의 문맥적/의미적 구조를 고려하기 못하고 중복 단어가 상위 순위에 나타날 수 있음

### [ 단어 간의 문맥적 구조 고려를 위한 개선방안 ] – KeyBERTInspired 활용

- 토픽을 대표하는 단어 = 토픽의 대표 문서와 유사도가 높은 단어
- 불용어(the, is, a 등)의 자연제거 효과가 있음



## BERTopic 개선하기 : c-TF-IDF의 개선


### [ 단어 간의 문맥적 구조 고려를 위한 개선방안 ] – MMR의 활용

- 중복 단어가 상위 순위에 나타나는 문제를 여전히 KeyBERTInspired는 해결하지 못함
- MMR Score를 도입하여 이미 선발된 상위 단어와 유사성이 높은 단어를 제외하는 원칙으로 활용

| Topic | Original                                                | Updated                                                 |
|-------|---------------------------------------------------------|---------------------------------------------------------|
| 0     | speech   asr   recognition<br>  end   acoustic          | speech   asr   error  <br>model   training              |
| 1     | medical   clinical  <br>biomedical   patient  <br>he... | clinical   biomedical  <br>patient   healthcare  ...    |
| 2     | sentiment   aspect  <br>analysis   reviews  <br>opinion | sentiment   analysis  <br>reviews   absa   polarity     |
| 3     | translation   nmt  <br>machine   neural   bleu          | translation   nmt   bleu  <br>parallel   multilin...    |
| 4     | summarization  <br>summaries   summary  <br>abstract... | summarization  <br>document   extractive  <br>rouge ... |

## BERTopic 개선하기 : LLM의 활용

- BERTopic을 포함한 토픽 모형은 토픽 별 주요 단어를 출력하는 데에는 탁월한 성능을 보이지만 그 토픽의 주제를 해석하는 데에는 인간의 해석이 필수적임
- 인간의 개입이 반영될 수 있음



## BERTopic 개선하기 : LLM의 활용

- BERTopic을 포함한 토픽 모형은 토픽 별 주요 단어를 출력하는 데에는 탁월한 성능을 보이지만 그 토픽의 주제를 해석하는 데에는 인간의 해석이 필수적임
- 인간의 개입이 반영될 수 있음
- 프롬프트 엔지니어링에 대해서는 6장에서 공부함

```
1 import openai
2 from bertopic.representation import OpenAI
3 import pandas as pd
4
5 # 1. OpenAI API 클라이언트 설정
6 client = openai.OpenAI(api_key="sk-proj-eKNohP8MvpM0pIx0Se7yx-uxSZjeJurilX7UXSY4hiKrhi1_L0PBkqn0Ae_9LV8rROY3HEAlxT3B1bkFJZapAt-J0")
7
8 # 2. 프롬프트 정의 ([DOCUMENTS]와 [KEYWORDS] 태그 필수 포함)
9 prompt = """
10 I have a topic that contains the following documents:
11 [DOCUMENTS]
12
13 The topic is described by the following keywords: [KEYWORDS]
14
15 Based on the information above, extract a short topic label in the following format:
16 topic: <short topic label>
17 """
18
19 # 3. OpenAI Representation 모듈 설정
20 representation_model = OpenAI(
21     client,
22     model="gpt-4o-mini", # 비용 대비 성능이 뛰어난 추천 모델
23     exponential_backoff=True, # Rate Limit 발생 시 자동 재시도
24     chat=True,
25     prompt=prompt,
26     nr_docs=4, # 프롬프트에 넣을 대표 문서 개수
27     doc_length=100, # 각 문서당 최대 길이 (단어 수)
28     tokenizer="whitespace" # doc_length 자르기 기준 (whitespace 필수 지정)
29 )
30
31 # 4. 기존 topic_model의 토픽 표현 업데이트 (클러스터링 재실행 X)
32 topic_model.update_topics(abstracts, representation_model=representation_model)
33
34 # 5. 결과 확인
35 topic_model.get_topic_info()
```

참고) 총 사용한 credit은 0.01 \$

BERTopic 개선하기 : LLM의 활용

- LLM이 BERTopic의 주요한 단어를 기반으로 해석을 하여 인간의 부담을 최소화시켰음

| Topic | Original                                                                                                                | Updated                                                                                                 |
|-------|-------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------|
| 0     | encoder   phonetic   transcription   speech   decoding   trained   spoken   decoder   language   voice                  | Advances in Self-Supervised Learning for Automatic Speech Recognition                                   |
| 1     | nlp   biomedical   ehr   clinical   ehrrs   language   text   dataset   data   for                                      | Enhancing Clinical Decision-Making through Advanced NLP and Knowledge Representation in Biomedical Data |
| 2     | translation   translate   translations   multilingual   monolingual   neural   language   bilingual   german   decoding | Neural Machine Translation Enhancements and Hybrid Approaches                                           |
| 3     | summarization   summarizers   summaries   summary   sentences   abstractive   text   task   sequence   sentence         | Advanced Approaches in Text Summarization                                                               |
| 4     | visual   captioning   multimodal   textual   visually   language   representations   text   retrieval   semantic        | Multimodal Learning for Visual and Textual Integration                                                  |
| 5     | hate   hateful   language   offensive   languages   cyberbullying   harassment   classifiers   twitter   annotated      | Hate Speech Detection in Social Media                                                                   |
| 6     | gendered   gender   bias   biases   pronouns   language   biased   nlp   female   male                                  | Gender Bias in Natural Language Processing                                                              |
| 7     | relation   relations   relational   extracting   sentences   sentence   extract   semantic   extraction   learning      | Relation Extraction Techniques and Challenges                                                           |
| 8     | reasoning   logic   logical   solving   solve   solver   thought   language   solvers   prompting                       | Enhancing Multi-Step Reasoning in Language Models through Chain-of-Thought Prompting                    |
| 9     | entities   entity   labeled   name   names   annotation   named   annotated   labeling   datasets                       | Cross-Lingual Named Entity Recognition Techniques                                                       |




Figure 5-24. The top 20 topics visualized.

## 요약

- 텍스트 클러스터링은 분류의 기능도 하는 동시에 탐색적 데이터 분석을 도와줌
- 텍스트 클러스터링의 성능 개선을 위해 임베딩 모델을 사용하고, 우수한 클러스터링 도구를 활용하고 있음
- BERTopic은 SBERT, UMAP, HDBSCAN을 활용한 텍스트클러스터링과 c-TF-IDF 기반의 토픽 표현의 두 단계로 이루어져 있음
  - 각 5단계 파이프라인은 독립적이므로, 충분히 개선이 가능하며 모듈화로 변형 BERTopic을 만들기 용이함
  - LLM을 마지막 파이프라인에 얹어서 토픽의 해석에 인간의 개입을 줄이는 방법도 가능함